


Clínica II

Modelos de linguagem

Uma coluna nova a partir do texto das sentenças

Insper



Insper.edu.br

Um trabalho com cliente

Um trabalho com cliente

Diferente de outros trabalhos finais, este tem um cliente.

Com o que o grupo precisa se preocupar aqui que num trabalho final comum não precisaria?

Um trabalho com cliente

RESPOSTA

preocupação

o que o cliente pergunta

custo

quanto vou pagar para rodar a base?

velocidade

em quanto tempo sai o resultado?

experiência de quem usa

quem vai usar consegue rodar e entender?

custo-efetividade

o resultado vale o que custa?

Tudo isso começa em duas decisões: usar um modelo de linguagem ou não e, se sim, **qual**.


Onde comparar modelos

O Artificial Analysis (artificialanalysis.ai) testa os modelos por conta própria e publica três medidas:

medida	como sai
inteligência	um índice de 0 a 100, a partir de baterias de testes
velocidade	tokens por segundo na resposta
preço	dólares por milhão de tokens

O índice mede testes gerais, e não a tarefa do grupo. Só testar numa amostra diz se o modelo **serve para o cliente**.

Inteligência contra preço



Cada ponto é um dos 169 modelos com preço, em 05/10/2026. **Em vermelho, a fronteira.** Os quadrados pretos são o modelo da demonstração, com pouco e com muito raciocínio.

A fronteira de Pareto

Um modelo está na fronteira quando **nenhum outro mais barato é mais inteligente**. Fora dela, sempre há um modelo melhor pelo mesmo preço, ou mais barato com a mesma inteligência.

na fronteira	índice	US\$ por milhão
MiMo-V2.6-Flash	37,9	0,18
GPT-6 Luna	38,1	0,20
GLM 5.3 Flash	41,8	0,24
MiMo-V2.6-Pro	46,3	0,54
Muse Spark 1.3	48,1	2,00
Claude Sonnet 5.5	56,0	4,00
Claude Opus 5.5	57,6	8,00

É a fronteira de **05/10/2026**. Sai modelo novo toda semana: consulte o site no dia da escolha.

Onde rodar

onde	o que dá de graça
Groq, plano gratuito	sem cartão; 1.000 pedidos por dia; é o da demonstração
Google Cloud	US\$ 300 por 90 dias, com cartão
AWS	US\$ 100, mais até US\$ 100 por tarefas, por 12 meses
Azure for Students	US\$ 100 por 12 meses, sem cartão

Nas nuvens, os créditos pagam modelos de vários fornecedores. Se o cliente exigir que os dados fiquem no Brasil, pergunte ao provedor, modelo a modelo: a região de São Paulo existe, mas **nem todo modelo roda nela**.

A coluna que falta

22.866 sentenças e uma pergunta

Um exemplo: uma base com 22.866 sentenças do TJSP em ações contra bancos, disponibilizadas entre 2024 e 2026. O cliente quer saber **em quantas o pedido foi negado, e por quê**.

As colunas da base

identificação	onde	o quê
cd_processo, id_processo	comarca, foro, vara	classe, assunto
magistrado	data_disponibilizacao	decisao, o texto inteiro

Ler as 22.866 sentenças

Nenhuma coluna diz o resultado: ele está no texto de decisao. Uma sentença da base tem, em média, 1.189 palavras.

Quantas horas o grupo levaria para ler todas, a 200 palavras por minuto?

Ler as 22.866 sentenças

RESPOSTA

```
palavras = 22866 * 1189  
horas = palavras / 200 / 60  
print(round(horas))
```

2266

São 283 dias de oito horas, sem pausa para anotar. Ler tudo à mão não cabe no semestre: o grupo precisa de um programa que leia por ele.

Procurar a palavra

Marcar as sentenças procedentes

```
import re
dispositivos = [
    "JULGO IMPROCEDENTES os pedidos da exordial.",
    "JULGO PROCEDENTE EM PARTE o processo",
    "julgo procedentes os pedidos da parte requerente",
    "JULGO EXTINTO o processo, sem resolução de mérito",
]
for texto in dispositivos:
    print(bool(re.search("procedente", texto, re.I)))
```

O grupo marca como procedente a sentença em que a palavra aparece. Preveja as quatro linhas e diga, para cada uma, se a marcação está certa.

Marcar as sentenças procedentes

RESPOSTA

True

True

True

False

A primeira é **improcedência**: "IMPROCEDENTES" contém "procedente". A segunda é procedência em parte, contada como procedência inteira. Só a terceira e a quarta estão certas.

A correção da colega

```
import re
dispositivos = [
    "JULGO IMPROCEDENTES os pedidos da exordial.",
    "JULGO PROCEDENTE EM PARTE o processo",
    "julgo procedentes os pedidos da parte requerente",
    "JULGO EXTINTO o processo, sem resolução de mérito",
]
for texto in dispositivos:
    print(bool(re.search(r"\bprocedente", texto, re.I)))
```

O `\b` exige que a palavra comece ali. Preveja de novo: o que ainda sai errado?

A correção da colega

RESPOSTA

False

True

True

False

"IMPROCEDENTES" saiu, mas a procedência **em parte** continua contada como procedência. Cada conserto fecha um buraco e deixa outro.

A palavra na base inteira

o texto contém	sentenças
"procedente"	12.454
"improcedente"	7.348
"parcialmente procedente" ou "procedente em parte"	4.136
"julgo procedente"	2.505

E há "JULGO PROCEDENTE, em parte", "homologo a desistência", que não é acordo, e "JULGO IMPROCEDENTE o pedido de indenização por danos morais" numa sentença que concedeu os danos materiais.

Por que o pedido foi negado

Em muitas dessas ações, o autor diz que nunca contratou o empréstimo. Um motivo frequente de improcedência é o juiz concluir que **o banco provou a contratação**. Três trechos com esse motivo:

"A prova produzida revela que a assinatura aposta no contrato partiu do punho subscritor da parte autora."

"Fê-lo, por certo, porque tomou os empréstimos, recebeu o dinheiro em conta e com isso anuiu."

"A contratação eletrônica, mediante uso de senha pessoal e intransferível [...] confirma a existência e validade do negócio jurídico."

Escreva um padrão que ache, nas 22.866, as sentenças com esse motivo.

Por que o pedido foi negado

RESPOSTA

Os três trechos dizem a mesma coisa sem uma palavra em comum. "Assinatura", "contrato" ou "senha" também aparecem em sentenças em que o banco **não** provou nada.

O padrão procura uma forma escrita. O motivo é um sentido, e cada juiz o escreve de um jeito.

Regex ou modelo de linguagem

	regex	modelo de linguagem
serve para	formato fixo: número CNJ, valor em R\$, inscrição na OAB	sentido: o motivo, a tese, se houve fraude
custo	nenhum, roda no computador	cobra por token e tem limite de uso
como erra	no texto que foge do padrão	com respostas plausíveis e erradas

Pedir ao modelo

Uma pergunta ao modelo pelo código

```
from langchain_groq import ChatGroq

modelo = ChatGroq(model="openai/gpt-oss-120b")
texto = "JULGO IMPROCEDENTES os pedidos da exordial."
resposta = modelo.invoke("Qual foi o resultado? " + texto)
print(resposta.content)
```

O modelo roda nos computadores da empresa que o oferece. O programa manda o texto pela internet e recebe a resposta. A empresa precisa saber de quem é a conta: a **chave de API**.

O que acontece numa chamada

passo

- 1 o programa monta o pedido: o modelo, o texto e a chave
- 2 manda o pedido pela internet aos servidores do Groq
- 3 o Groq confere a chave, roda o modelo e conta os tokens
- 4 devolve a resposta e a contagem de tokens
- 5 lança o uso na conta dona da chave: cobrança, ou o limite do plano gratuito

A chave é a única coisa no pedido que diz **de quem é a conta**.

A chave escrita no código

Animação no navegador: `animacao-api-llm.html`, cenário código.

O que é um .env

Um arquivo de texto na pasta do projeto, com o que não pode ir no código. O ChatGroq acha a chave no ambiente.

o arquivo .env

```
GROQ_API_KEY=gsk_...
```

o notebook

```
from dotenv import load_dotenv
load_dotenv() # o .env vai para o ambiente
modelo = ChatGroq(model="openai/gpt-oss-120b")
```

O notebook vai para a banca; o .env **fica na máquina**. No Colab, a chave vai em "Secrets", o ícone de chave.

A chave no ambiente

Animação no navegador: [animacao-api-llm.html](#), cenário ambiente.

A sugestão do colega

O grupo vai publicar o notebook num repositório público para a banca conferir. Um colega propõe deixar a chave do Groq escrita numa célula, para a banca rodar sem configurar nada, e apagar a linha depois da banca.

Qual o problema nisso?

A sugestão do colega

RESPOSTA

Quem abrir o arquivo enquanto ele estiver no ar usa a chave, e o uso cai na conta do grupo: no plano pago, a cobrança; no gratuito, o limite diário, que acaba antes do trabalho.

Apagar depois não desfaz: o histórico do repositório e as cópias guardam a versão com a chave. A chave exposta se **revoga** no painel do Groq, e a banca usa a própria chave, lida do ambiente.

No notebook: seções 1 a 3

Instalar, criar a chave do Groq, guardá-la no .env e fazer a primeira pergunta ao modelo.

Quanto custa

Mandar a base inteira

A base tem 177.873.339 caracteres. Cada 4 caracteres valem cerca de 1 token, e o preço é por milhão de tokens.

modelo	entrada, por milhão de tokens
A	US\$ 5,00
B	US\$ 0,15

Quanto custa mandar cada sentença uma vez, contando só a entrada, em cada modelo?

Mandar a base inteira

RESPOSTA

```
tokens = 177873339 / 4  
print(round(tokens / 1_000_000 * 5.00, 2))  
print(round(tokens / 1_000_000 * 0.15, 2))
```

222.34

6.67

São 44,5 milhões de tokens. O modelo A custa 33 vezes o B, e a resposta de cada sentença ainda se paga à parte.

O limite do plano gratuito

plano gratuito do Groq, um modelo	limite
tokens por dia	200 mil
tokens por minuto	8 mil
sentenças por dia, na média da base	cerca de 100
dias para a base inteira	222

E 275 sentenças passam de 8 mil tokens sozinhas: nem cabem num minuto do plano gratuito.

Reduzir antes de mandar

etapa	sentenças	tokens
a base como chegou	22.866	44,5 milhões
sem textos repetidos	20.013	38,6 milhões
só o assunto que a pergunta pede	menos	menos
amostra para testar o prompt	50	cerca de 100 mil

A base repete 2.853 textos inteiros. Testar o prompt numa amostra custa centavos e acha o erro antes da conta grande.

O que são tokens de raciocínio

Muitos modelos escrevem um rascunho antes de responder: releem o pedido, testam uma leitura, conferem. O rascunho também é feito de tokens, e **se paga como saída**.

o dispositivo

"JULGO IMPROCEDENTE a pretensão [...]. Em relação ao pedido formulado no item "c" [...], o feito fica extinto sem resolução de mérito"

rascunho do modelo, 203 tokens (trecho)

"The main ruling is "JULGO IMPROCEDENTE a pretensão" [...]. There's a secondary part about item "c" [...], but the main result of the sentence is "improcedente.""

resposta

improcedente

Dois jeitos de gastar computação

	no treino	no uso
o que cresce	o modelo, os dados, o tempo de treino	o rascunho antes de cada resposta
quem paga	o fornecedor, uma vez	quem usa, a cada pergunta
exemplo	gpt-oss de 20 para 120 bilhões de parâmetros: índice 9,0 → 11,6	Qwen3.8 27B sem raciocínio e no máximo: índice 20 → 34

Os dois melhoram a resposta. O do uso **entra na conta do cliente**, a cada sentença.

Os tokens de raciocínio

Um modelo cobra US\$ 0,15 por milhão de tokens de entrada e US\$ 0,60 por milhão de saída. Por sentença: 2.000 tokens de entrada, 100 de resposta e 1.500 de raciocínio.

Quanto custam 20.000 sentenças?

Os tokens de raciocínio

RESPOSTA

```
entrada = 2000 * 0.15 / 1_000_000
saida = (100 + 1500) * 0.60 / 1_000_000
print(round(20000 * (entrada + saida), 2))
```

25.2

O raciocínio se cobra como **saída**. Quem conta só a resposta chega a US\$ 7,20, um terço do valor real.

No notebook: seções 4 e 5

Carregar a base, tirar as repetidas, calcular o custo e sortear uma amostra que caiba no plano gratuito.

Do texto à coluna

Cinco respostas do modelo

Respostas reais de um modelo a "Qual foi o resultado desta sentença?"

1. "O resultado desta sentença foi totalmente desfavorável para quem entrou com a ação (o autor). [...]"
2. "O resultado dessa sentença foi favorável à pessoa que entrou com a ação (autor), embora tenha sido classificada como "procedente em parte" [...]"
3. "O resultado foi a extinção do processo sem que o juiz julgasse quem está certo ou errado [...]"
4. "O resultado desta sentença foi o encerramento (extinção) do processo, porque o autor [...] desistiu [...]"
5. "O resultado foi a vitória da autora [...]. O juiz julgou o pedido procedente [...]"

Quantas são procedentes? Que código contaria isso nas 22.866 respostas?

Cinco respostas do modelo

RESPOSTA

Uma, a quinta. A primeira é improcedência e abre por "desfavorável"; a segunda é procedência em parte e abre por "favorável".

O modelo entendeu as cinco, mas respondeu cada uma de um jeito. Contar essas respostas exige de novo procurar palavras: o **problema da regex voltou**.

Uma tabela entra, uma tabela sai

O `dataframeit` manda cada linha de uma tabela a um modelo e devolve a mesma tabela com colunas novas. Ele precisa de quatro coisas:

o quê	para quê
a tabela	uma linha por sentença; <code>text_column</code> diz qual coluna tem o texto
uma classe	cada campo vira uma coluna; a <code>description</code> diz ao modelo o que coletar
um prompt	a instrução; o texto da linha entra no lugar de <code>{texto}</code>
<code>provider</code> e <code>model</code>	onde roda e qual modelo responde

Descrever o que coletar

```
from typing import Literal
from pydantic import BaseModel, Field
class Decisao(BaseModel):
    resultado: Literal[
        "procedente", "parcialmente procedente",
        "improcedente", "extinto sem resolução do mérito",
        "homologação", "outro"] = Field(
        description="O resultado da sentença.")
```

Motivos e má-fé na mesma classe

Os dois campos seguintes da classe `Decisao`, depois do resultado

```
motivos: list[Literal[
    "contratação comprovada", "encargos sem abusividade",
    "golpe por culpa da vítima ou de terceiro",
    "falta de prova mínima", "prescrição ou decadência",
    "outro"]] = Field(description="Por que o pedido "
                                "foi negado.")
ma_fe: bool = Field(description="A sentença fala em "
                                "litigância de má-fé?")
```

Três tipos de campo

tipo	o modelo é obrigado a
<code>Literal[...]</code>	escolher exatamente uma das opções listadas
<code>list[Literal[...]]</code>	escolher nenhuma, uma ou várias das opções
<code>bool</code>	responder True ou False

O tipo fixa o formato da resposta. A description diz ao modelo **o que coletar** em cada campo.

Uma chamada para a tabela inteira

```
from dataframeit import dataframeit

# sentencas: o DataFrame da base, uma linha por sentença
# Decisao: a classe dos slides anteriores
tabela = dataframeit(sentencas, Decisao,
                     "Classifique a sentença: {texto}",
                     provider="groq", text_column="decisao",
                     model="openai/gpt-oss-120b")
print(tabela["resultado"].value_counts())
```

Em cada linha, o texto da coluna decisao entra no lugar de {texto}, e o que volta preenche as colunas da classe.

O que volta

na tabela devolvida	o que é
<code>resultado, motivos, ma_fe</code>	uma coluna por campo da classe
<code>_dataframeit_status</code>	aparece se alguma linha falhou, e diz qual
<code>_error_details</code>	o motivo da falha, linha a linha

Se o limite do plano gratuito interromper, rodar **a mesma chamada** de novo processa só as linhas que faltam.

Três sentenças viram três linhas

Animação no navegador: [animacao-extracao.html](#), cenário sentencas.

A classe da outra pergunta

O cliente quer saber também se a sentença reconheceu fraude na contratação e de quanto foi a indenização por dano moral, quando houve.

Escreva a classe com esses dois campos.

A classe da outra pergunta

RESPOSTA

```
class Indenizacao(BaseModel):  
    fraude_reconhecida: bool = Field(  
        description="Reconheceu fraude na contratação?")  
    valor_dano_moral: float | None = Field(  
        description="Dano moral em reais; vazio se não  
houve")
```

O valor é número, e não texto, para a coluna poder ser somada. Aceitar None deixa o campo **vazio** quando não houve dano moral, em vez de obrigar o modelo a inventar um zero.

No notebook: seções 6 e 7

Escrever a classe com as descriptions e rodar o dataframeit na amostra.

O modelo acertou?

Conferir cinco anotações

Leia o trecho e confira o que o modelo anotou

trecho	resultado	ma_fe
"HOMOLOGO o pedido de desistência e JULGO EXTINTO O PROCESSO SEM RESOLUÇÃO DO MÉRITO [...]"	homologação	False
"JULGO PARCIALMENTE PROCEDENTE a ação para: DECLARAR a inexigibilidade do débito [...]"	parcialmente procedente	False
"JULGO PROCEDENTE o pedido para [...] condenar os réus [...] ao pagamento de R\$ 15.000,00 [...]. Ainda JULGO IMPROCEDENTE o pedido de indenização por dano moral."	improcedente	False
"Finalmente, não há que se falar em litigância de má-fé. [...] JULGO IMPROCEDENTE o pedido inicial."	improcedente	True
"JULGO IMPROCEDENTE a ação em relação ao [banco]. [...] Em relação à [corrê], [...] julga-se extinto o feito sem resolução de mérito"	extinto sem resolução do mérito	False

Conferir cinco anotações

RESPOSTA

Só a segunda está certa, e nenhum erro é ao acaso:

- | | |
|---|--|
| 1 | "homologo" puxou para homologação, mas desistência é extinção sem resolução do mérito |
| 3 | um pedido acolhido e outro negado: parcialmente procedente |
| 4 | a sentença cita a má-fé para afastá-la: ma_fe é False |
| 5 | a extinção é só quanto à corrê; contra o banco, improcedente |

A classe não dizia **o que conta** como cada opção.

Sortear, ler e comparar

Animação no navegador: [animacao-validade.html](#), cenário amostra.

Melhorar a descrição

```
resultado: Literal[..., "acordo homologado", "outro"] = Field(
    description="Resultado do pedido principal. Acordo
    homologado "
    "é só acordo entre as partes; desistência homologada
    é "
    "extinção. Um pedido acolhido e outro negado é
    parcial.")
ma_fe: bool = Field(
    description="True só se condenou o autor por má-fé; "
    "citar para afastar é False.")
```

Depois, rodar de novo e conferir numa **amostra nova**.

Quantas sentenças ler

Animação no navegador: [animacao-amostragem.html](#).

O que escrever no relatório

Com a descrição melhorada, o grupo sorteou outras 50 das 20.013 sentenças, leu cada uma e comparou com o modelo: 46 resultados iguais.

Escreva o que o relatório pode afirmar sobre as 20.013.

O que escrever no relatório

RESPOSTA

Que o modelo concordou com a leitura humana em 46 de 50 sentenças sorteadas: 92%, com margem de uns **7,5 pontos** para mais ou para menos. O número estima a base inteira sem garanti-la, porque as outras 19.963 ninguém leu.

Cada divergência se relê: o erro pode ser do modelo ou de quem leu. Se os erros do modelo tiverem padrão, o relatório diz qual, para quem usar a tabela saber onde desconfiar.

No notebook: seções 8 e 9

Ler o dispositivo de cada sentença da amostra, comparar com o modelo e guardar a tabela.